

UNIVERSIDAD DEL VALLE DE GUATEMALA

Deep Learning



**Proyecto 1, Monitoreo transaccional
Detectar lo que el orden revela**

Informe para el comité de riesgos, Banco del Altiplano

Erick Guerra - 23208
Carlos Alburez - 231311

GUATEMALA, 4 de septiembre del 2026

1. Qué nos pidieron y qué hicimos

El área de riesgos nos planteó una pregunta concreta. Ustedes sospechan que el orden en que ocurren las transacciones de un cliente contiene información sobre fraude que las variables agregadas actuales no alcanzan a capturar. Nos pidieron averiguar si eso es cierto, bajo qué condiciones y cuánto vale esa información en quetzales.

Para responder, construimos tres modelos que compiten en las mismas condiciones. Al primero lo llamamos Modelo A, y es una réplica razonable de lo que hoy hace el sistema del banco, un árbol de decisión que solo ve variables agregadas por ventana de tiempo, sin ningún concepto de orden. El Modelo B es una red neuronal recurrente (GRU) que lee la secuencia completa de transacciones anteriores de cada cliente, en el orden en que ocurrieron. El Modelo C es nuestra apuesta propia, y combina las dos fuentes de información, la secuencia y los agregados, en una sola red.

Como no teníamos acceso a datos reales del banco, generamos nuestros propios datos sintéticos con un simulador que construimos para este proyecto. Esa decisión nos permitió controlar exactamente qué patrones de fraude dependen del orden y cuáles no, algo que hubiera sido muy difícil de comprobar con datos reales sin etiquetas del mecanismo de fraude.

2. De dónde salen los datos y cómo los organizamos

Simulamos 3,000 clientes durante 180 días con un generador que produce transacciones legítimas y tres tipos de fraude. Usamos una semilla fija, 2027, para que cualquiera pueda reproducir exactamente el mismo conjunto de datos corriendo nuestro generador de nuevo.

En total obtuvimos 407,524 transacciones. La tasa de fraude es baja, como en cualquier problema real de este tipo, entre 0.30% y 0.39% según el periodo. Por eso decidimos desde el principio no usar exactitud como métrica principal, porque un modelo que nunca marcara nada como fraude tendría casi 99.7% de exactitud y sería completamente inútil para el banco.

Diseñamos tres mecanismos de fraude con propósitos distintos. Escalada son varias compras pequeñas seguidas de una compra grande en poco tiempo, y es el que más depende del orden, si se revuelve la secuencia el patrón desaparece aunque las transacciones sigan siendo las mismas. Ráfaga son entre 8 y 12 transacciones en menos de 45 minutos, y ahí el orden pesa menos que el conteo, así que esperábamos que incluso un modelo sin secuencia lo detectara razonablemente bien. Comercio atípico es una transacción grande, a una hora inusual, en un comercio que ese cliente nunca había usado, no depende del orden, pero sí de saber si ese comercio es nuevo para ese cliente en particular, algo que las variables agregadas de A no capturan porque solo miden qué tan común es el comercio en general.

Antes de entrenar nada, anotamos que esperábamos que el Modelo A fallara sobre todo en comercio atípico, porque no tiene forma de saber si un comercio es nuevo para un cliente en particular. Esa expectativa se confirmó en validación, y la explicamos con más detalle en la sección 4.

Para que la comparación fuera justa, dividimos los datos por tiempo, no al azar. Entrenamos con los días 0 a 119, ajustamos arquitectura y umbrales con los días 120 a 149, y dejamos los días 150 a 179 completamente sellados hasta el final, sin mirarlos ni una sola vez mientras tomábamos decisiones. Todas las estadísticas que usamos para normalizar variables, elegir arquitectura y fijar umbrales salieron únicamente de entrenamiento y validación. El conjunto de prueba se abrió una sola vez, ya con todo congelado.

3. Cómo comparamos A y B

Los tres modelos entregan un puntaje continuo de riesgo entre 0 y 1, no una decisión binaria. La decisión de dónde poner el umbral la tomamos después, con el análisis económico que describimos en la sección 6. En el conjunto de prueba, que solo revisamos una vez, estos fueron los resultados.

Modelo	AUC-PR	Precisión	Exhaustividad	F1	Costo mensual (test)
A, árboles sobre agregados	0.749	0.452	0.764	0.568	Q 255,120
B, GRU sobre la secuencia	0.775	0.668	0.741	0.703	Q 253,980
C, GRU con agregados	0.783	0.355	0.809	0.494	Q 234,540

Tabla 1. Comparación de los tres modelos en el conjunto de prueba, con el umbral que cada uno fijó en validación.

B mejora a A en todas las métricas de calidad de ranking y en precisión, aunque el costo total apenas baja un poco, porque el umbral que ya usa A no es tan malo en promedio. La ganancia más clara de leer la secuencia no se ve en el promedio general, se ve cuando miramos por tipo de mecanismo, que es justamente lo que hicimos en la siguiente sección.

4. Lo que descubrimos sobre el valor del orden

No nos conformamos con que B tuviera mejor AUC-PR que A. Eso solo demuestra que B es mejor modelo, no que esté usando el orden para lograrlo. Para comprobarlo diseñamos dos pruebas pensadas para hacer fallar nuestra propia conclusión.

La primera es la prueba obligatoria. Tomamos el Modelo B ya entrenado y revolvimos el orden del historial de cada cliente, sin tocar las transacciones, sus variables agregadas ni la transacción objetivo, que siempre queda al final de la secuencia. Repetimos esto con cinco semillas distintas para no depender de una sola mezcla. Si B realmente usa el orden, su desempeño debería caer mucho al perder esa información.

Y cayó mucho. En validación, el AUC-PR de B pasó de 0.79 a un promedio de 0.29 al revolver el historial, una caída de más de medio punto. Repetimos exactamente la misma prueba en el conjunto de prueba sellado, para confirmar que no era un efecto raro de validación, y el resultado

fue casi idéntico, de 0.775 bajó a 0.243, una caída de 0.53. Con esa evidencia, sí podemos afirmar que el Modelo B está usando genuinamente el orden de las transacciones, no solo los eventos que contiene.

La segunda prueba la elegimos nosotros, desglosar el desempeño por mecanismo de fraude, porque sospechábamos que el orden no pesa igual en los tres tipos. Y así fue. La mejora de B sobre A es enorme en escalada, de 0.67 a 0.78 de AUC-PR, que es justamente el mecanismo que diseñamos para depender del orden. Pero también encontramos que revolver el orden hunde a B en ráfaga casi tanto como en escalada, así que el orden también le está aportando algo ahí, con más fuerza de la que esperábamos.

La mala noticia la encontramos en comercio atípico. Ahí B se desempeña incluso peor que A, con un recall de cero, no detecta ni un solo caso en su umbral de operación. Tiene sentido, porque ni A ni B reciben ninguna señal de si el comercio es nuevo para ese cliente, y B además tiene muy pocos ejemplos de este mecanismo para aprender el patrón, solo 9 casos en validación. Esta es una limitación real que no escondemos, y en la sección 5 explicamos cómo la Apuesta C la mejora parcialmente.

5. Nuestra apuesta

Antes de entrenar el Modelo C, escribimos la hipótesis para no poder acomodarla después de ver los resultados. Creíamos que combinar la secuencia de B con las variables agregadas de A mejoraría el desempeño en todos los mecanismos, porque los agregados le dan al modelo memoria de ventanas más largas que las 20 transacciones que alcanza a ver directamente. Dijimos que lo consideraríamos útil solo si mejoraba el AUC-PR de validación en al menos 0.02 sobre el mejor de A o B, y si además reducía el costo económico en al menos 5%.

C sí redujo el costo, 7.2% menos que el mejor de los otros dos en validación. Pero solo mejoró el AUC-PR en 0.012, por debajo del 0.02 que nos habíamos exigido. Como pusimos las dos condiciones antes de ver el resultado, y solo se cumplió una, tenemos que ser honestos, nuestra apuesta, tal como la planteamos, no se cumplió.

Dicho esto, encontramos algo que vale la pena reportar aunque la apuesta formal haya fallado. Al desglosar C por mecanismo, vimos que recupera buena parte de comercio atípico, el punto débil de A y B, el recall pasa de cero en B a 0.89 en C. También mantiene la mejora de escalada. Lo que pierde es precisión en general, porque genera más falsas alarmas, y eso explica por qué el AUC-PR global no subió tanto como esperábamos aunque el comportamiento por mecanismo sí mejoró.

Nuestra conclusión sobre la apuesta es esta, no cumplió el criterio que nos impusimos, así que no podemos decir que ganó limpiamente. Pero sí encontramos una señal genuina y útil, sobre todo en el mecanismo que más nos preocupaba, y la tomamos en cuenta en la recomendación final.

6. Dónde ponemos el umbral y cuánto vale eso

El comité nos dio dos números para trabajar, un fraude no detectado cuesta en promedio Q4,200, y bloquear una transacción legítima por error cuesta Q180. Con esos costos, buscamos en validación el umbral que minimiza el costo total para cada modelo, y usamos ese mismo umbral, ya congelado, para evaluar en el conjunto de prueba.

Para A, el umbral que minimiza costo es 0.85. Para B es 0.33. Para C es 0.23, bastante más bajo, porque C está diseñado para arriesgarse a más falsas alarmas con tal de no dejar pasar fraude, y eso es justamente lo que el costo económico premia, dado que un fraude no detectado cuesta veintitrés veces más que bloquear una transacción legítima.

En el conjunto de prueba, que representa aproximadamente 30 días de operación, el costo total fue de Q255,120 con A, Q253,980 con B y Q234,540 con C. Eso significa que, comparado con el sistema actual, cambiar a B ahorraría alrededor de Q1,140 al mes, una diferencia pequeña. Cambiar a C ahorraría cerca de Q20,580 al mes, que sí es una diferencia con peso, aunque C sea la apuesta que técnicamente no cumplió su propio criterio de mejora.

7. Nuestra recomendación y sus límites

Con toda esta evidencia, no recomendamos reemplazar de un día para otro el sistema actual por ninguno de estos modelos. Recomendamos complementarlo con un modelo secuencial,

priorizando C, pero con dos condiciones claras.

Primero, la precisión de C es baja, 35%, lo que significa que casi dos de cada tres transacciones que bloquearía son en realidad legítimas. El costo de Q180 por bloqueo no captura todo el daño real de eso, como la molestia del cliente o el riesgo de que abandone el banco, así que antes de llevarlo a producción recomendamos acompañarlo de una zona de revisión humana para los puntajes intermedios, en lugar de bloquear automáticamente todo lo que supere el umbral.

Segundo, algunos de nuestros mecanismos de fraude tienen muy pocos casos en validación y prueba, comercio atípico apenas llega a 9 o 10 casos en cada partición. Eso hace que las métricas de ese mecanismo específico sean ruidosas, y no nos da la confianza suficiente para decir que el problema está resuelto, solo que hay una señal prometedora que merece validarse con más datos, idealmente reales.

Un patrón de error concreto que vale la pena vigilar, tanto B como C pierden precisión en escalada, aceptando como sospechosas transacciones que se parecen a un patrón de escalada legítimo, por ejemplo un cliente que compra varias cosas pequeñas seguidas por costumbre, sin intención fraudulenta. Cambiaríamos nuestra recomendación si, al probar con datos reales, ese tipo de falso positivo resultara mucho más frecuente de lo que vimos en los datos sintéticos, porque ahí el costo operativo de las falsas alarmas superaría el ahorro que estamos proyectando.

En resumen, el orden sí aporta información real, lo demostramos con dos pruebas independientes, y esa información vale aproximadamente Q20,580 al mes en el escenario que evaluamos. Pero la forma en que la aprovechamos hoy, el Modelo C, todavía tiene una precisión que preferimos no automatizar sin supervisión, y una apuesta que no debemos vender como un éxito absoluto solo porque el costo bajó.

Matriz de evidencias

Evidencia	Dónde aparece	Conclusión	Limitación
Integridad de datos	Sección 2	Datos sintéticos reproducibles (semilla 2027), partición temporal estricta y sin fuga de información.	Datos simulados, no reales. Falta validar contra transacciones reales antes de producción.
Comparación A y B	Tabla 1, sección 3	B mejora AUC-PR y precisión sobre A en el conjunto de prueba.	La mejora agregada es moderada y se concentra en mecanismos específicos.
Valor del orden	Sección 4	La permutación del historial hunde el AUC-PR de B en 0.53 puntos en el conjunto de prueba, y el efecto se repite en validación.	El mecanismo comercio atípico no se beneficia del orden.
Apuesta del equipo (C)	Sección 5	C no cumplió el criterio de AUC-PR que nos impusimos (+0.012 contra +0.02 exigido), aunque sí el de costo.	La mejora que sí encontramos, en comercio atípico, se apoya en solo 9 a 10 casos por partición.
Decisión económica	Sección 6	C ahorra cerca de Q 20,580 al mes frente al sistema actual, con umbral 0.23.	El costo de bloqueo (Q180) no recoge la fricción real con el cliente.
Recomendación	Sección 7	Complementar el sistema actual con un modelo secuencial, con revisión humana en la zona de puntaje intermedio.	La precisión de C es baja (35%). La recomendación depende de validar con datos reales.